

Semi-supervised Learning with Deep Generative Models

Ольга Гребенькова

Байесовское мультимоделирование

27 октября 2021 г.

О чем пойдет речь?

Обучение с частичным привлечением учителя

Обучающий датасет содержит как размеченные, так и неразмеченные данные. Этот метод особенно полезен, когда трудно извлечь из данных важные признаки или разметить все объекты – трудоемкая задача.

Где встречается?

Очень много применений: анализ медицинских изображений, анализ речи, парсинг текста и т.д

Варианты решений

Самообучение, совместное обучение, полуавтоматические опорные вектора (S3VM), генеративные сети

- ① данные

$$(\mathbf{X}, \mathbf{Y}) = (\mathbf{x}_1, y_1), \dots, (\mathbf{x}_N, y_N),$$

где $\mathbf{x}_i \in \mathbb{R}^D$, а $y_i \in \{1, \dots, L\}$.

- ② скрытая переменная и распределение вектора переменных в скрытом пространстве

$$\mathbf{z}_i$$

$$p(\mathbf{z}) = N(\mathbf{z}|0, \mathbf{I});$$

- ③ распределение итоговых наблюдений при условии скрытой переменной

$$p_{\theta}(\mathbf{x}|\mathbf{z}) = f(\mathbf{x}; \mathbf{z}, \theta),$$

где $f(\mathbf{x}; \mathbf{z}, \theta)$ является подходящей функцией правдоподобия. Вероятности формируются нелинейным преобразованием с параметрами θ из набора скрытых переменных \mathbf{z} .

- ④ сэмплы из $p(\mathbf{z}|\mathbf{x})$ рассматриваем как признаки для обучения классификатора (SVM, многоклассовая регрессия).

- ❶ распределение вектора переменных в скрытом пространстве

$$p(\mathbf{z}) = N(\mathbf{z}|0, \mathbf{I});$$

❷

$$p(y) = \text{Cat}(y|\pi),$$

где $\text{Cat}(y|\pi)$ мультиномиальное распределение.

- ❸ распределение итоговых наблюдений при условии скрытых переменных

$$p_{\theta}(\mathbf{x}|y, \mathbf{z}) = f(\mathbf{x}; y, \mathbf{z}, \theta),$$

где $f(\mathbf{x}; y, \mathbf{z}, \theta)$ является подходящей функцией правдоподобия.

- ❹ из апостериорного распределения $p(y|\mathbf{x})$ получаем классы неразмеченных данных.
- ❺ M1+M2 сначала обучаем скрытое представление \mathbf{z}_1 с помощью модели 1. Далее обучаем модель 2 используя эмбединги из \mathbf{z}_1 вместо \mathbf{x} . Итоговая модель:

$$p_{\theta}(\mathbf{x}, y, \mathbf{z}_1, \mathbf{z}_2) = p(y)p(\mathbf{z}_2)p_{\theta}(\mathbf{z}_1|y, \mathbf{z}_2)p_{\theta}(\mathbf{x}|\mathbf{z}_1).$$

- Введем распределение фиксированной формы аппроксимирующее неизвестное апостериорное $p(\mathbf{z}|\mathbf{x})$:

$$q_\phi(\mathbf{z}|\mathbf{x}).$$

-

$$M1 : q_\phi(\mathbf{z}|\mathbf{x}) = N(\mathbf{z}|\mu_\phi(\mathbf{x}), \text{diag}(\sigma_\phi^2(\mathbf{x})))$$

$$M2 : q_\phi(\mathbf{z}|y, \mathbf{x}) = N(\mathbf{z}|\mu_\phi(y, \mathbf{x}), \text{diag}(\sigma_\phi^2(\mathbf{x}))) \quad q_\phi(y|\mathbf{x}) = \text{Cat}(y|\pi_\phi(\mathbf{x}))$$

При этом:

$$q_\phi(\mathbf{z}, y|\mathbf{x}) = q_\phi(\mathbf{z}|\mathbf{x})q_\phi(y|\mathbf{x})$$

- Будем рассматривать в качестве лосса вариационную нижнюю границу правдоподобия модели. Для первой модели она выглядит следующим образом:

$$\log p_\theta(\mathbf{x}) \geq \mathbb{E}_{q_\phi(\mathbf{z}|\mathbf{x})}[\log p_\theta(\mathbf{x}|\mathbf{z})] - KL[q_\phi(\mathbf{z}|\mathbf{x})||p_\theta(\mathbf{z})] = -J(\mathbf{x})$$

- Если мы знаем класс объекта:

$$\log p_{\theta}(\mathbf{x}, y) \geq \mathbb{E}_{q_{\phi}(\mathbf{z}|\mathbf{x}, y)}[\log p_{\theta}(\mathbf{x}|y, \mathbf{z}) + \log p_{\theta}(y) + \log p(\mathbf{z}) - \log q_{\phi}(\mathbf{z}|\mathbf{x}, y)] = -L(\mathbf{x}, y)$$

- Если класс объекта неизвестен

$$\begin{aligned}\log p_{\theta}(\mathbf{x}) &\geq \mathbb{E}_{q_{\phi}(y, \mathbf{z}|\mathbf{x})}[\log p_{\theta}(\mathbf{x}|y, \mathbf{z}) + \log p_{\theta}(y) + \log p(\mathbf{z}) - \log q_{\phi}(y, \mathbf{z}|\mathbf{x})] = \\ &= \sum_y q_{\phi}(y|\mathbf{x})(-L(\mathbf{x}, y)) + H(q_{\phi}(y|\mathbf{x})) = -U(\mathbf{x}).\end{aligned}$$

- Тогда функция для всего датасета:

$$J = \sum_{(\mathbf{x}, y) \sim p_l} L(\mathbf{x}, y) + \sum_{\mathbf{x} \sim p_u} U(\mathbf{x})$$

- Расширенная лосс функция:

$$J_{\alpha} = J + \alpha \mathbb{E}_{p_l(\mathbf{x}, y)}[-\log q_{\phi}(y|\mathbf{x})].$$

Algorithm 1 Learning in model M1

```

while generativeTraining() do
   $\mathcal{D} \leftarrow \text{getRandomMiniBatch}()$ 
   $\mathbf{z}_i \sim q_\phi(\mathbf{z}_i | \mathbf{x}_i) \quad \forall \mathbf{x}_i \in \mathcal{D}$ 
   $\mathcal{J} \leftarrow \sum_n \mathcal{J}(\mathbf{x}_i)$ 
   $(\mathbf{g}_\theta, \mathbf{g}_\phi) \leftarrow (\frac{\partial \mathcal{J}}{\partial \theta}, \frac{\partial \mathcal{J}}{\partial \phi})$ 
   $(\theta, \phi) \leftarrow (\theta, \phi) + \Gamma(\mathbf{g}_\theta, \mathbf{g}_\phi)$ 
end while
while discriminativeTraining() do
   $\mathcal{D} \leftarrow \text{getLabeledRandomMiniBatch}()$ 
   $\mathbf{z}_i \sim q_\phi(\mathbf{z}_i | \mathbf{x}_i) \quad \forall \{\mathbf{x}_i, y_i\} \in \mathcal{D}$ 
   $\text{trainClassifier}(\{\mathbf{z}_i, y_i\})$ 
end while

```

Algorithm 2 Learning in model M2

```

while training() do
   $\mathcal{D} \leftarrow \text{getRandomMiniBatch}()$ 
   $y_i \sim q_\phi(y_i | \mathbf{x}_i) \quad \forall \{\mathbf{x}_i, y_i\} \notin \mathcal{O}$ 
   $\mathbf{z}_i \sim q_\phi(\mathbf{z}_i | y_i, \mathbf{x}_i)$ 
   $\mathcal{J}^\alpha \leftarrow \text{eq. (9)}$ 
   $(\mathbf{g}_\theta, \mathbf{g}_\phi) \leftarrow (\frac{\partial \mathcal{L}^\alpha}{\partial \theta}, \frac{\partial \mathcal{L}^\alpha}{\partial \phi})$ 
   $(\theta, \phi) \leftarrow (\theta, \phi) + \Gamma(\mathbf{g}_\theta, \mathbf{g}_\phi)$ 
end while

```



(a) Handwriting styles for MNIST obtained by fixing the class label and varying the 2D latent variable z



(b) MNIST analogies



(c) SVHN analogies